

11_RAG(Retrieval) 大纲

1、Retrieval模块的设计意义	1
1.1 大模型的局限	1
1) 知识滞后	1
2) 知识缺失	1
3) 幻觉	1
1.2 什么是RAG	1
1.3 RAG优缺点	4
RAG的优点	4
RAG的缺点	4
1.4 RAG工作流程	4
环节1: Source (数据源)	4
环节2: Load (加载)	5
环节3: Transform (转换)	5
环节3.1: Text Splitting (文档拆分)	5
环节4: Embed (嵌入)	6
环节5: Store (存储)	7
环节6: Retrieve (检索)	7
2、详细使用流程	7
2.1 环境准备	7
2.1.1 安装依赖	7
2.1.2 准备数据	8
2.2 文档加载器 Document Loaders	8
2.2.1 加载txt	8
2.2.2 加载CSV	9
2.2.3 加载JSON	10
举例1: 使用JSONLoader文档加载器加载	10
举例2: 提取04-response.json文件中指定的文本	11
加载json文件中所有的数据	11
加载json文件中employees[]中的name字段	11
提取04-response.json文件中嵌套在data.items[].content的文本	12
提取04-response.json文件中嵌套在data.items[]里的title、content和其文本	13
2.2.4 加载pdf	13
方式1: PyPDFLoader	14
方式2: MinerU	16
2.2.5 加载word	18
2.2.6 加载Markdown	19
举例1: 使用UnstructuredMarkdownLoader加载md文	19
举例2: 精细分割文档, 保留结构信息	20
2.2.7 加载HTML(了解)	21
2.2.8 加载File Directory(了解)	24
2.2.9 了解: BaseLoader、Document类	25
BaseLoader类分析	25

Document类分析	26
2.3 文档切分器 Text Splitters	26
2.3.1 为什么分割/切分/分块？	26
2.3.2 Chunking拆分的策略	27
方法1：根据句子切分	27
方法2：按照固定字符数来切分	27
方法3：按固定字符数来切分，结合重叠窗口（overlapping windows）	27
方法4：递归字符切分方法	27
方法5：根据语义内容切分	27
2.3.3 几个常用的文档切分器的方法的调用	28
2.3.4 具体实现	28
① CharacterTextSplitter：Split by character	28
举例1：字符串文本的分割	28
举例2：指定分割符	29
举例3：指定分割符	30
② RecursiveCharacterTextSplitter：最常用	30
举例1：使用split_text()方法	31
举例2：使用create_documents()方法1	32
举例3：使用create_documents()方法2	34
举例4：使用split_documents()方法	41
举例5：自定义分隔符	43
③ TokenTextSplitter/CharacterTextSplitter：Split by tokens	44
举例1：使用TokenTextSplitter	45
举例2：使用CharacterTextSplitter	46
④ SemanticChunker：语义分块	47
1. breakpoint_threshold_type（断点阈值类型）	48
2. breakpoint_threshold_amount（断点阈值量）	49
3. sentence_split_regex（句子切分的正则表达式）	49
⑤ HTMLHeaderTextSplitter(了解)	49
⑥ CodeTextSplitter(了解)	50
举例1：支持的语言	51
举例2：python语言	51
⑦ MarkdownTextSplitter(了解)	51
举例：md数据类型	51
2.4 文档嵌入模型 Text Embedding Models	52
2.4.1 嵌入模型概述	52
2.4.2 嵌入模型选型与初始化	54
选型：使用硅基流动平台的嵌入模型	54
初始化方式	54
初始化方式1：init_embeddings()	54
初始化方式2：OpenAIEmbeddings()	54
2.4.3 句子的向量化（embed_query）	54
2.4.4 文档的向量化（embed_documents）	55
2.5 向量存储(Vector Stores)	56
2.5.1 向量数据库的理解	56
2.5.2 常用的向量数据库	57
2.5.3 案例：民法典客服知识库	57
① 全局配置	58
② 初始化Milvus	58
③ 初始化 Embedding 模型	59

④ 读取文档并切分	60
⑤ 生成向量并写入 Milvus	62
⑥ 初始化模型与Agent	64
⑦ 检索逻辑 (Retrieval)	64
⑧ 生产与回答生成	65